Comparación de técnicas de aprendizaje automático para riesgo crediticio

Francisco Elián Ríos Patricio

Planteamiento del problema

- Clasificar clientes como “buenos” o “riesgosos”
- Conjunto de datos: 1000 registros.
- 70 % buenos / 30 % riesgosos
- Problema binario supervisado

Enfoque metodológico

1. Limpieza y transformación
2. División 70/30 con estratificación
3. Pipeline de preprocesamiento
4. Validación cruzada 5-fold
5. Evaluación final en test

Age	Job	Credit Amount	Housing	Duration	Risk
34	Skilled	4000	Own	18	Good
51	Unskilled	1200	Rent	12	Bad
29	Skilled	1500	Free	24	Good

Arquitectura con pipeline

- ColumnTransformer
- SimpleImputer
- StandardScaler en KNN
- Modelo final al final del pipeline

Métricas utilizadas

- Accuracy = (TP + TN)/(TP + TN + FP + FN)
- Precision = TP/(TP + FP)
- Recall = TP/(TP + FN)
- F1-Score=2 ((Precision*Recall)/(Precision+Recall))
- ROC-AUC

KNN (K - Nearest Neighbors)

- Método basado en distancia
- No paramétrico
- Fácil de interpretar
- n_neighbors=5
- Distancia euclidiana
- Requiere escalado

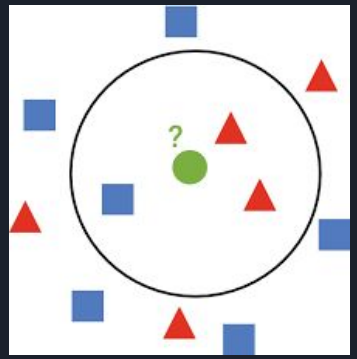

Resultados de KNN

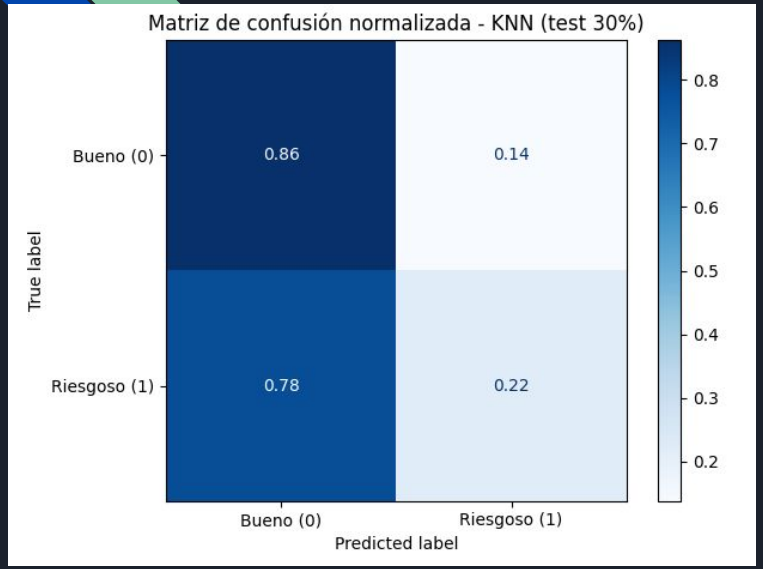

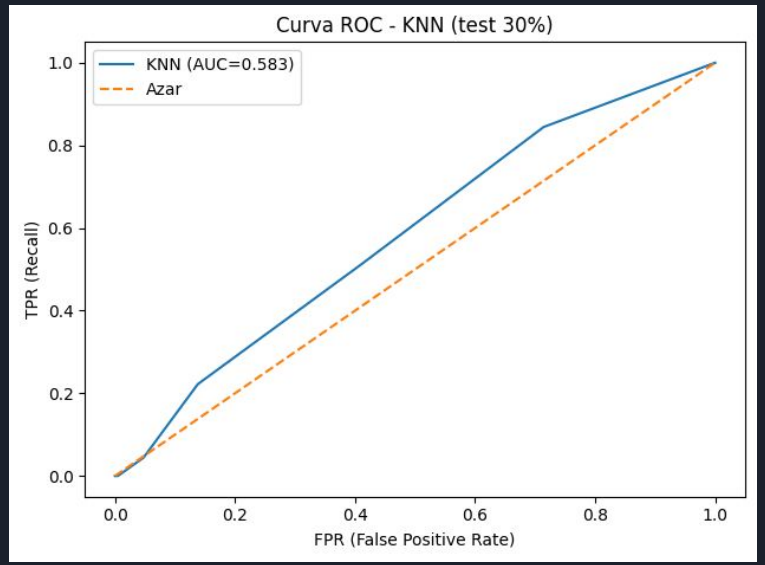

- Accuracy: 0.670
- Precision: 0.408
- Recall: 0.222
- F1-score: 0.288
- ROC-AUC: 0.583

Árboles de decisión

- Modelo basado en reglas
- No requiere escalado
- Captura relaciones no lineales
- Interpretabilidad
- criterion (Gini)
- max_depth
- random_state

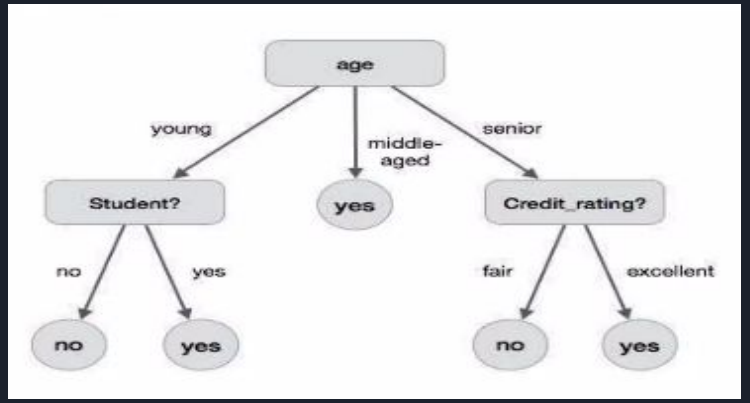

Árboles de decisión

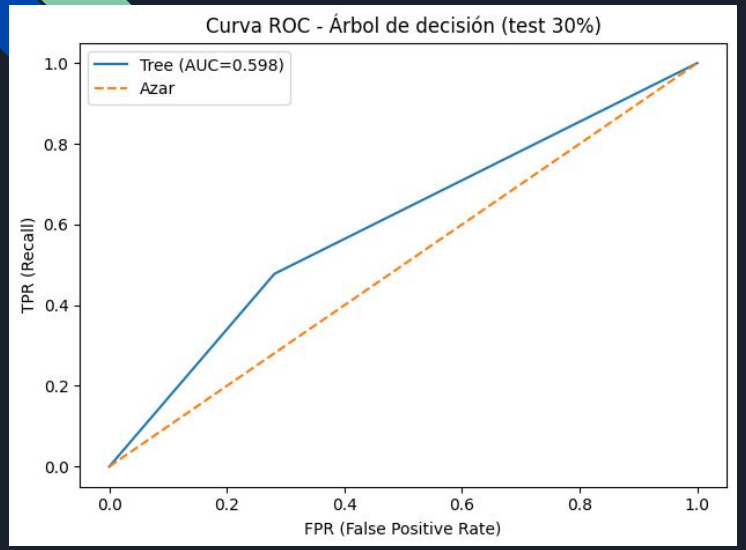

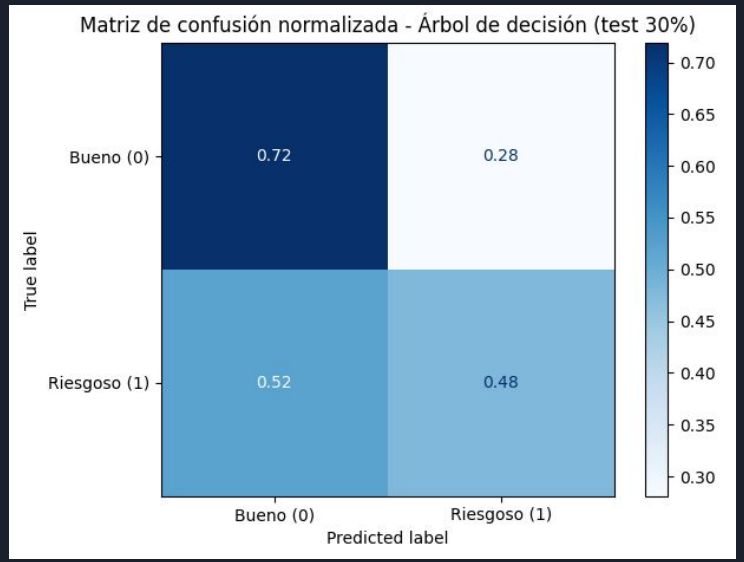

- Accuracy: 0.647
- Precision: 0.422
- Recall: 0.478
- F1-score: 0.448
- ROC-AUC: 0.598

Comparación directa

Métrica	KNN	Árbol de Decisión
Accuracy	0.670	0.647
Precision	0.408	0.422
Recall	0.222	0.478
F1-score	0.288	0.448
ROC-AUC	0.583	0.598

- KNN prioriza clase mayoritaria.
- Árbol mejora sensibilidad.
- Ambos tienen AUC bajo.

Trabajo futuro y Conclusión

- Ajustar hiperparámetros
- Modelos más robustos (regresión logística, random forest, svm)
- El árbol de decisión muestra un mejor desempeño al momento de detectar clientes riesgosos, lo cual es la prioridad en el riesgo crediticio.